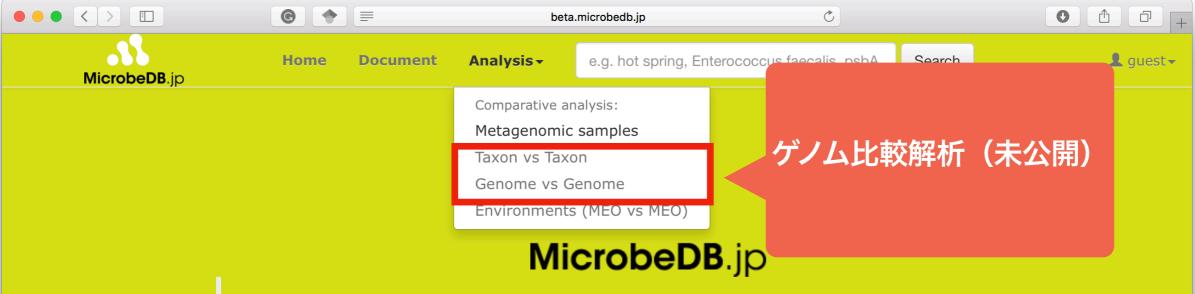
MicrobeDB.jpポータル:

開発中のゲノム比較解析機能の紹介



Integrating and representing genome, metagenome, taxonomy resources and the analysis datasets with Semantic Web Technologies.

Database statistics

Total number of Metagenomic samples (SRA/SRS):

- with taxonomic analysis results:

- with functional analysis results:

- with functional analysis results:

Total number of Assembled Genomes (RefSeq/Genbank):

Total number of Strains (JCM/NBRC):

Total number of Environmental terms in ontology (MEO):

Show graph

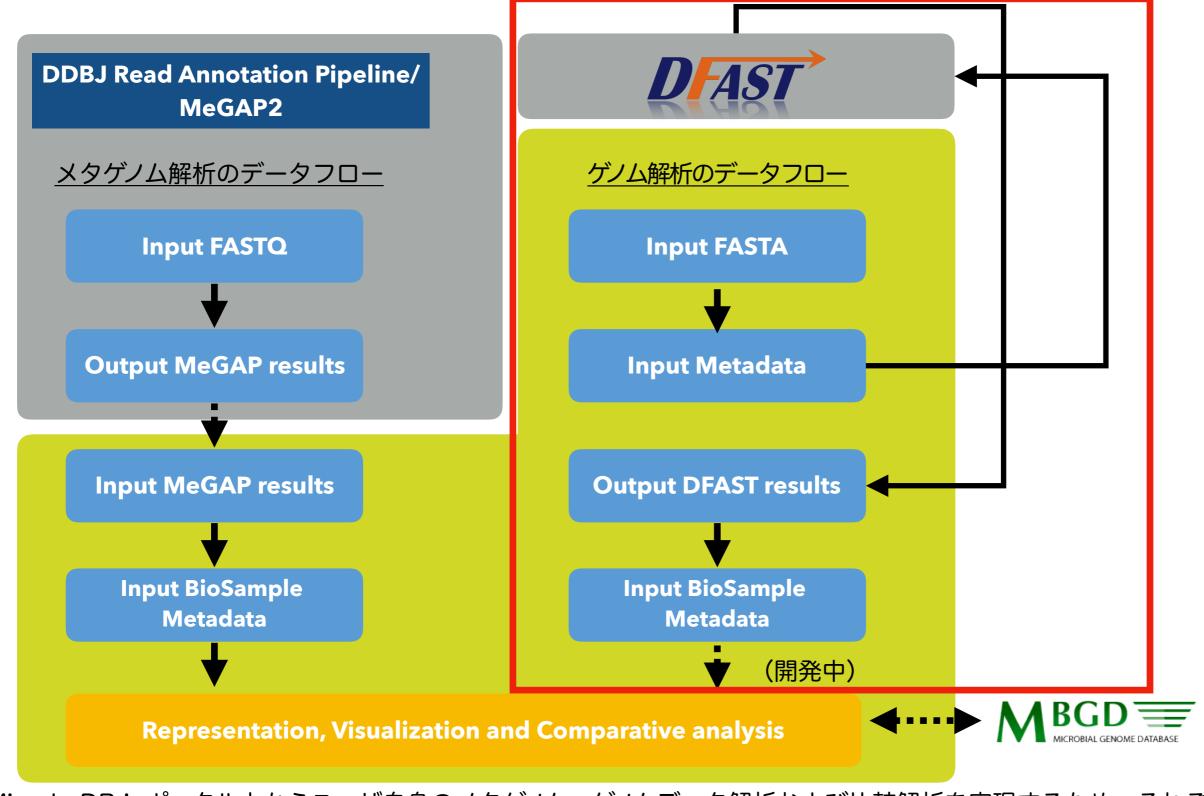
Features

Q Keyword Search

MicrobeDB.jp provides a keyword search function with a simple interface. The keyword search gives the user free-text access to the literal fields of all RDF/OWL resources on MicrobeDB.jp. See document#sesource for more information.

https://beta.microbedb.jp/#

<u>MicrobeDB.jp解析パイプラインとの連携</u>



MicrobeDB.jpポータル上からユーザ自身のメタゲノム・ゲノムデータ解析および比較解析を実現するため、それぞれメタゲノム解析パイプラインMeGAP、微生物ゲノムアノテーションパイプラインDFASTと連携させた。MeGAPについては非常に計算リソースを要求するため、国立遺伝学研究所スパコンで運用中のDDBJ Read Annotation Pipelineを介して実行後、解析結果が入力となる。

doi: 10.1093/bioinformatics/btx713

Advance Access Publication Date: 2 November 2017

Applications Note



Genome analysis

DFAST: a flexible prokaryotic genome annotation pipeline for faster genome publication

Yasuhiro Tanizawa, Takatomo Fujisawa and Yasukazu Nakamura*

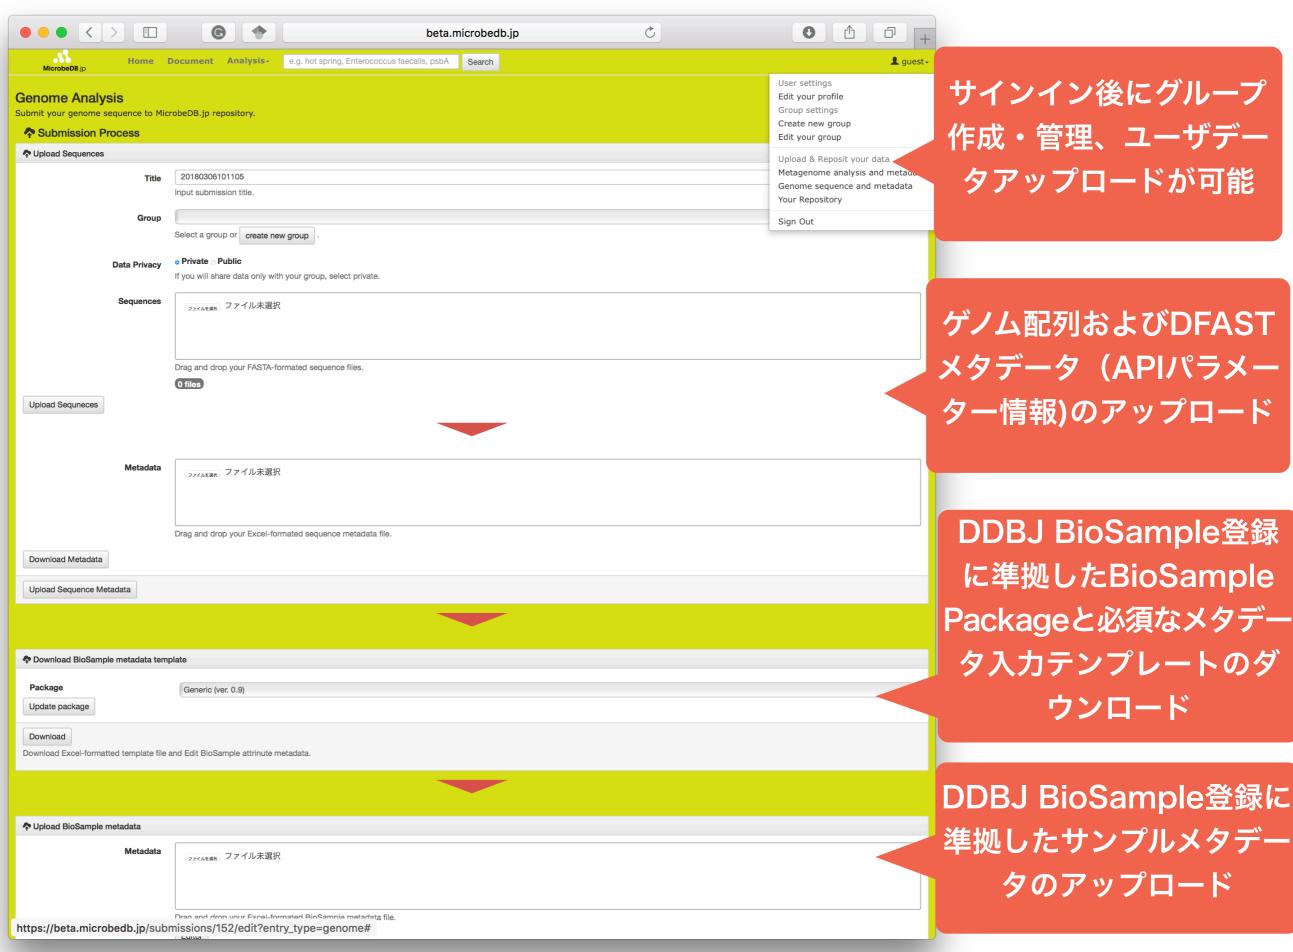
Center for Information Biology, National Institute of Genetics, Research Organization of Information and Systems, 1111 Yata, Mishima 411-8540, Japan

*To whom correspondence should be addressed.

Associate Editor: John Hancock

Received on August 15, 2017; revised on October 27, 2017; editorial decision on October 30, 2017; accepted on November 6, 2017

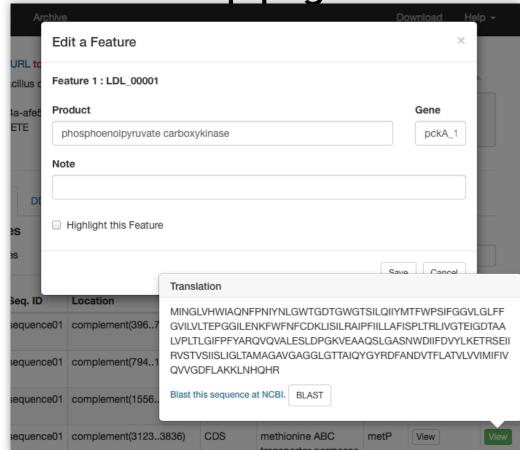
ゲノム比較解析のためのデータアップロード機能



DFAST webサービス

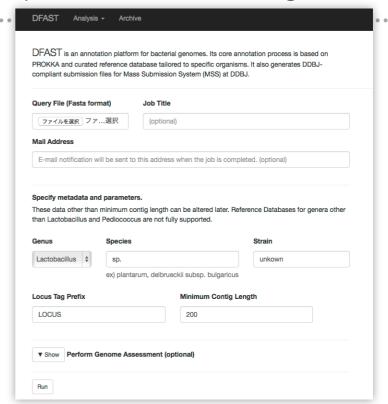
DFAST and DAGA are integrated genome annotation tools and resources. DFAST is an annotation platform for bacterial genomes. Its core annotation process is based on PROKKA and curated reference database tailored to specific organisms. It also generates DDBJcompliant submission files for Mass Submission System (MSS) at DDBJ. DAGA is a genome archive that sores bacterial genomes obtained from DDBJ/ENA/GenBank and Sequence Read Archive (SRA). All the genomes deposited in DAGA are consistently annotated using DFAST. This website provides genome resources for Lactic Acid Bacteria. **DDBJ Fast Annotation and Submission Tool** D-AST Upload your Genome, Annotate, and Submit to DDBJ. Select reference database to use Lactic Acid Bacteria (v. 0.9) **B-versions** Cyanobacteria Manually curated, based on CyanoBase. (v. 0.1) Manually curated. (v. 0.1) For general use. Mainly constructed and automatically curated using protein sequences from 'Reference Genomes' in RefSeq. Actinobacteria Same as above. Subset for Actinobacteria. Firmicutes Same as above. Subset for Firmicutes. Proteobacteria Same as above. Subset for Proteobacteria You can see the Example of the annotation from here.

Top page



Annotation editor

https://dfast.nig.ac.jp



Job submission

nput metadata by filling lease refer to the instru- you want to add items	ction for more infor		登録ファイル作成に必要なメタデータをフォームに入力します。 入力項目の詳細な説明や作成例については アノテーションファ ル作成概説 を参照してください。			
nanually after download	ing the annotation f	île.		フォームにない項目はファイルダウンロード後に手動で修正を		
ou can "Preview" the pr	ovided metadata.	ou can also import		ってください。 メタデータを入力せずに空欄のままファイルを 成し、ダウンロード後に手動で入力することも可能です。		
netadata from another D						
ext box below. By defau pecies name or a strain				メタデータ入力後 "Preview" ボタンで確認ができます。また、: ョブ ID を入力して他のジョブからメタデータをコピーすること		
heck the "Override orga			できます。デフォルトでは	できます。デフォルトでは生物種名や菌株名などのデータはコピ		
			ーされませんが、"Override 場合、これらのデータも上	organism specific data" を有効にし まきされます		

▲ Hide Form	Preview		import another job's metadata. anism specific data.	.3		
ienus*	s* Species*					
Lactobacillus	*	delbrueckii subs	sp. lactis			
Strain*		Type Strain	Culture Collection			
DSM 20076		NO \$	DSM:20076			
ocus Tag Prefix	BioProj	ect*	BioSample*	Sequence Read Archive		
LDL	PRJD	B99999	SAMD999999	DRR999999		
LDL	PRJD	B99999	SAMD999999			

DDBJ submission file editor

DFAST: DDBJ Fast Annotation and Submission Tool

V 0.1 (2016.1) Tanizawa et al., BMFH (2016)

軽量アノテーションパイプライン Prokka をベース 生物種群ごとにキュレーションされたDBを用意 メタデータ・アノテーション結果を編集するGUI → DDBJ compliant な登録ファイルの生成

Web APIによるジョブ投入・管理機能の実装 汎用的な参照DBを用意

独自アノテーションエンジンDFAST-coreの新規開発

Stand-alone ツールとしても公開 (GitHub: nigyta/dfast_core) Tanizawa et al., Bioinformatics (2017)

V 1.0 (2017.8)

DFAST-core: 新バックグラウンドエンジン

スタンドアローンツールとしても利用可能

https://github.com/nigyta/dfast_core

Linux/Mac, Python 2.7/3.4- で動作

外部バイナリー同梱

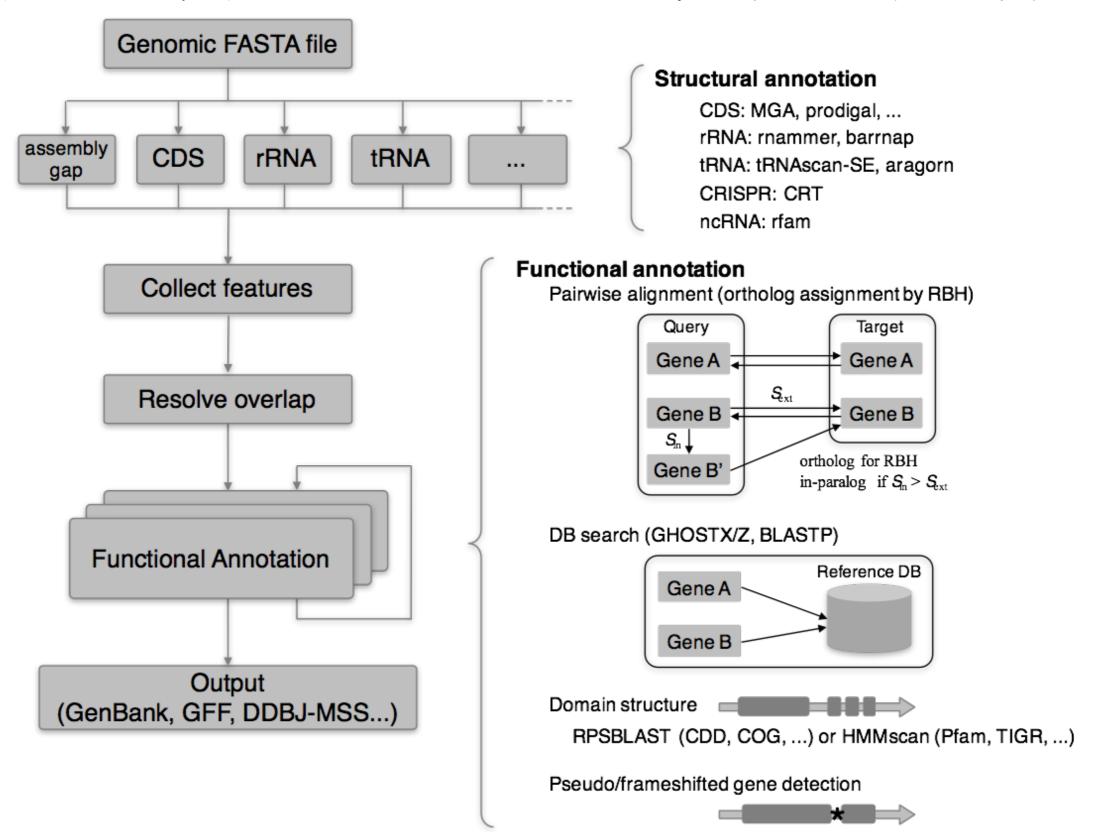
カスタマイズ可能なワークフロー

高速かつリッチなアノテーション GHOSTX をデフォルトで利用 偽遺伝子・フレームシフトの検出

DDBJへの登録ファイル作成

DFAST-core アノテーションワークフロー

参照DB・外部ツール・パラメータ等を自由に設定可能



典型的なサイズのバクテリアゲノムを約5分でアノテーション

Prokka と同等の実行時間でより多くの遺伝子の機能を予測

参照DBのサイズはProkkaの20倍

BLASTPを使った場合の実行時間の1/10

セレノシステインを含む3遺伝子の検出に成功

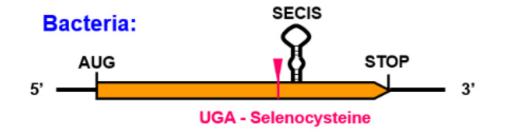
Escherichia coli O26 アノテーション結果

Data source / Annotation tool	INSDC	RefSeq (PGAP)	DFAST	Prokka	MiGAP
Total CDS	5795	6243	5740	5759	5721
Pseudogene frameshift or internal stop / partial	276	337 (250/87)	344 (158/186)	[30*]	-
Selenoprotein	3	1	3	-	-
with COG number	-	-	3965	-	4392
Unknown function	1203	1514	1347	2068	418
tRNA	101	101	105	105	100
rRNA	22	22	22	22	22
CRISPR arrays	-	2	2	2	-
Running time	-	-	3m27s	3m20s	4h43m

^{*} Indicated as possible pseudo in the log file (INSDC: GCA 000091005.1, RefSeq: GCF 000091005.1)

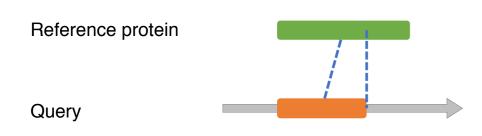
DFASTで対応しているアノテーション出力例

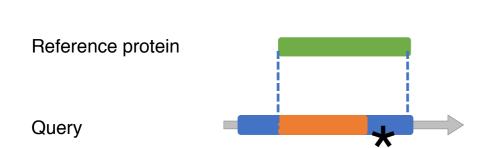
翻訳の例外



/inference="DESCRIPTION:similar to AA sequence:RefSeq:NP_310105.1"
/transl_except=(pos:2026834..2026836,aa:Sec)
/note="codon on position 196 is selenocysteine opal codon."
/note="NP_310105.1 nitrate-inducible formate dehydrogenase-N alpha subunit (Escherichia coli O157:H7 str. Sakai) [pid:99.8%, q_cov:100.0%, s_cov:100.0%, Eval:0.0e+00]"

偽遺伝子・フレームシフトの検出





MBGD Cluster IDの アサイン(開発中) /note="Partial hit; WP_003643223.1 gluconate permease (Lactobacillus plantarum WCFS1) [pid:71.3%, q_cov:100.0%, s_cov:44.8%, Eval:6.5e-78]"
/note="frameshifted; deletion at around 14464"

/product="hypothetical protein"

s cov: 29.8%, Eval: 1.1e-15}"

/inference="similar to AA sequence:RefSeq:WP_003548611.1"
/inference="similar to AA sequence:MBGD:2015-01_default:16"
/codon_start=1
/product="AraC family transcriptional regulator"
/transl_table=11
/note="WP_003548611.1 AraC family transcriptional regulator
(Lactobacillus acidophilus NCFM) [pid:36.0%, q_cov:99.7%, s_cov:99.4%, Eval:8.0e-54]"
/note="MBGD: {gene_id: 'crn:CAR_RS11760', cluster_id: '16',

gene_description: 'transcriptional regulator', version:

'2015-01', tabid: 'default', pid: 40.2%, q cov: 31.1%,

ゲノム比較解析インターフェース (イメージ)



課題

ゲノムにおいては、MBGDオーソログ解析、メタゲノムにおいては、MeGAPメタゲノム解析(taxonomy/function)に大規模な計算リソースと時間を必要とするため、最新の公開データに関して解析データを含めたデータベースからの提供は困難である

今後の対応

- ゲノム、メタゲノムサンプルのメタデータについてはの更新を行い、 最新の公開データを対象とした比較解析のためのMeGAP, DFAST の実行はユーザ自身に委ねる
- MBGD、MeGAPによる解析結果の反映についてはメジャーリ リース時に対応